Problem Set 03 — Đồ họa, điều kiện hóa và cấu trúc ẩn

UET.MAT1052 — Xác suất thống kê

Hoàng Thị Điệp, Nghiêm Nguyễn Việt Dũng, Lê Thị Hường

Mục tiêu

Problem Set 03 luyện đúng các ý của Week 03:

- đọc một biểu đồ như **dữ liệu + ánh xạ + dạng hình học**;
- phân biệt **số lượng, tỉ lệ và mật độ**;
- hiểu **lọc, nhóm, tóm tắt** như một chuỗi lập luận;
- phân biệt tóm tắt **biên (marginal)** và **có điều kiện (conditional)**;
- nhận ra cấu trúc bị che bởi việc gộp nhóm, kể cả cơ chế kiểu Simpson;
- phát hiện khi một đồ họa đúng số nhưng khuyến khích một kết luận quá mạnh.

Chuẩn bị dữ liệu

Problem Set này dùng hai cách cung cấp dữ liệu:

1. **Bài 1–5 (Phần A):** dữ liệu cần thiết đã được cho trực tiếp trong đề; **không cần tải thêm file**.
2. **Bài 6–10 (Phần B):** tải tệp CSV từ **trang dữ liệu chính thức của OpenIntro**, lưu vào thư mục `data/`, sau đó đọc **file local** bằng `pandas`.

Trước khi làm Phần B, hãy tạo cấu trúc thư mục:

```
problem-set-03/
  problem_set_03.qmd
  data/
      county.csv
      run10.csv
      exam_grades.csv
      loans_full_schema.csv
      ncbirths.csv
```

Tải năm bộ dữ liệu OpenIntro sau. Trên mỗi trang, chọn **CSV file** và lưu đúng tên tệp như trong bảng.

Tệp local	Bộ dữ liệu	Trang dữ liệu chính thức
`data/county.csv`	`county`	https://www.openintro.org/data/index.php?data=county
`data/run10.csv`	`run10`	https://www.openintro.org/data/index.php?data=run10
`data/exam_grades.csv`	`exam_grades`	https://www.openintro.org/data/index.php?data=exam_grades
`data/loans_full_schema.csv`	`loans_full_schema`	https://www.openintro.org/data/index.php?data=loans_full_schema
`data/ncbirths.csv`	`ncbirths`	https://www.openintro.org/data/index.php?data=ncbirths

Sau khi tải, có thể kiểm tra nhanh:

```
from pathlib import Path
import pandas as pd

data_dir = Path("data")

county = pd.read_csv(data_dir / "county.csv")
run10 = pd.read_csv(data_dir / "run10.csv")
exam_grades = pd.read_csv(data_dir / "exam_grades.csv")
loans = pd.read_csv(data_dir / "loans_full_schema.csv")
ncbirths = pd.read_csv(data_dir / "ncbirths.csv")

print("county:", county.shape)
print("run10:", run10.shape)
print("exam_grades:", exam_grades.shape)
print("loans_full_schema:", loans.shape)
print("ncbirths:", ncbirths.shape)
```

> **Lưu ý.** Trong Phần B, không đọc dữ liệu trực tiếp từ URL và không dùng CSV mirror. Mỗi bài nên có thể chạy độc lập bằng cách đọc lại file tương ứng trong thư mục `data/`.

Phần A — Tính tay

Bài 1 — Chạy một pipeline bằng tay: `penguins`

Bảng dưới đây gồm 12 quan sát thật trích từ bộ `penguins` được STAT20 sử dụng.

ID	species	island	bill_length_mm	bill_depth_mm	body_mass_g	sex
1	Adelie	Torgersen	39.1	18.7	3750	male
2	Adelie	Torgersen	39.5	17.4	3800	female
3	Adelie	Torgersen	40.3	18.0	3250	female
4	Adelie	Torgersen	36.7	19.3	3450	female
5	Gentoo	Biscoe	46.1	13.2	4500	female
6	Gentoo	Biscoe	50.0	16.3	5700	male
7	Gentoo	Biscoe	48.7	14.1	4450	female
8	Gentoo	Biscoe	50.0	15.2	5700	male
9	Chinstrap	Dream	46.5	17.9	3500	female
10	Chinstrap	Dream	50.0	19.5	3900	male
11	Chinstrap	Dream	51.3	19.2	3650	male
12	Chinstrap	Dream	45.4	18.7	3525	female

Không chạy mã. Hãy thực hiện bằng tay pipeline sau:

```
(
    penguins_mini
    .query("bill_length_mm >= 45 and body_mass_g < 5000")
    .assign(heavy=lambda d: d["body_mass_g"] > 4000)
    .groupby("species", observed=True)
    .agg(
        n=("body_mass_g", "size"),
        p_heavy=("heavy", "mean"),
        mean_depth=("bill_depth_mm", "mean")
    )
)
```

1. Ghi lại **ID của các hàng còn lại sau `.query()`**.
2. Với từng hàng còn lại, tự ghi `heavy = True/False`.
3. Chia các hàng theo `species` và tính bằng tay `n`, `p_heavy`, `mean_depth`.
4. Giải thích bằng một câu vì sao trung bình của `True/False` lại là một tỉ lệ.
5. Nếu đổi thứ tự để `groupby("species")` xảy ra **trước** `.query(...)`, câu hỏi thống kê có còn giống hệt không? Giải thích; không cần viết mã.

Điểm cốt lõi: phải nhìn pipeline như một chuỗi biến đổi dữ liệu, không như một câu thần chú Python.

Bài 2 — Histogram mật độ bằng tay: khối lượng chim cánh cụt

Trong 342 cá thể `penguins` có ghi `body_mass_g`, số quan sát trong bốn khoảng sau là:

Khối lượng (kg)	Số cá thể
$[2.7, 3.5)$	71
$[3.5, 4.0)$	94
$[4.0, 5.0)$	110
$[5.0, 6.4]$	67

1. Tính **phần trăm** cá thể trong từng khoảng.
2. Vì các khoảng có chiều rộng khác nhau, hãy tính chiều cao histogram theo thang

$$\text{mật độ} = \frac{\text{phần trăm trong lớp}}{\text{chiều rộng lớp (kg)}}$$

với đơn vị **% trên mỗi kg**. 3. Vẽ histogram đúng trên giấy kẻ ô. Kiểm tra rằng **diện tích** bốn khối cộng lại xấp xỉ 100%. 4. Khoảng nào có **nhiều cá thể nhất**? Khoảng nào **dày đặc nhất trên mỗi kg**? Hai câu trả lời có giống nhau không? 5. Một bạn nhìn thấy cột $[3.5, 4.0)$ cao hơn cột $[4.0, 5.0)$ rồi kết luận "có nhiều chim 3.5–4.0 kg hơn 4.0–5.0 kg". Hãy chỉ ra lỗi.

Bài 3 — Cùng histogram, dữ liệu gốc có thể rất khác

Với 12 khối lượng đầu tiên (sau khi bỏ giá trị thiếu) của `penguins`, nếu dùng bốn lớp

$$[3000, 3500), \quad [3500, 4000), \quad [4000, 4500), \quad [4500, 5000),$$

thì số quan sát lần lượt là

$$5,\ 5,\ 1,\ 1.$$

1. Tự dựng **hai danh sách khác nhau**, mỗi danh sách gồm 12 khối lượng nguyên (gram), sao cho cả hai đều cho đúng histogram $5, 5, 1, 1$ trên.
2. Danh sách A phải đặt các giá trị càng gần **mép trái** của mỗi lớp càng tốt; danh sách B đặt các giá trị càng gần **mép phải** càng tốt.

3. Không dùng trung bình hay độ lệch chuẩn. Hãy nêu ít nhất **ba đặc điểm của dữ liệu gốc** mà histogram này không cho phép khôi phục.
4. Một sinh viên nói: "Nếu hai bộ dữ liệu có cùng histogram thì về mặt thống kê chúng là một." Hãy phản biện bằng chính hai danh sách bạn vừa dựng.

   Gợi ý tư duy: histogram là phép nén dữ liệu. Hỏi xem phép nén đã xóa thông tin nào.

Bài 4 — Chiều cao, diện tích và câu hỏi "có bao nhiêu?": `msleep`

STAT20 dùng bộ `msleep` gồm 83 loài động vật có vú. Nếu chia `sleep_total` (giờ/ngày) theo các khoảng không đều nhau, ta thu được:

Số giờ ngủ	Số loài
$[1.9, 5)$	11
$[5, 8)$	10
$[8, 12)$	31
$[12, 20]$	31

1. Tính phần trăm loài trong mỗi khoảng.
2. Tính mật độ "% trên mỗi giờ" cho mỗi khoảng.
3. Hai khoảng cuối có cùng 31 loài. Trong histogram mật độ, chúng có cao bằng nhau không? Vì sao?
4. Từ bảng này, có thể kết luận "có nhiều loài ngủ đúng 9 giờ hơn đúng 15 giờ" không? Giải thích.
5. Một đồ họa vẽ bốn cột **cùng độ rộng trên giấy** và lấy chiều cao bằng `11, 10, 31, 31`. Nó có thể dùng như bar chart của bốn nhãn khoảng, nhưng tại sao không được đọc nó như histogram trên một trục số liên tục?

Bài 5 — Tỉ lệ biên có thể che gần như toàn bộ cấu trúc nhóm

Trong `penguins`, xét biến chỉ báo

$$H = I(\texttt{body_mass_g} > 4000).$$

Trong 342 cá thể có khối lượng được ghi lại:

species	$H = 1$	số có dữ liệu	tỉ lệ $H = 1$
Adelie	35	151	23.2%
Chinstrap	15	68	22.1%

species	$H = 1$	số có dữ liệu	tỉ lệ $H = 1$
Gentoo	122	123	99.2%
Gộp	**172**	**342**	**50.3%**

1. Tính lại ba tỉ lệ theo loài và tỉ lệ gộp từ tử số/mẫu số; không dùng các phần trăm đã in sẵn.
2. Chứng minh bằng phép tính rằng 50.3% là một **trung bình có trọng số** của ba tỉ lệ theo loài.
3. Một báo cáo viết: "Khoảng một nửa chim cánh cụt vượt 4000 g, nên `species` không giúp dự đoán nhiều về việc vượt ngưỡng." Tỉ lệ 50.3% có hỗ trợ kết luận đó không?
4. Giữ nguyên ba tỉ lệ theo loài nhưng tưởng tượng một mẫu mới gồm đúng 100 cá thể với cơ cấu `10 Adelie, 10 Chinstrap, 80 Gentoo`. Ước tính tỉ lệ biên $H = 1$ của mẫu mới.
5. Làm lại với cơ cấu `45 Adelie, 45 Chinstrap, 10 Gentoo`. Hai kết quả khác nhau nói gì về vai trò của **trọng số nhóm**?

Phần B — Freedman

Khởi tạo Python

Bạn có thể dùng `pandas` và `plotnine`. Không bắt buộc dùng đúng đoạn mã dưới đây.

```
from pathlib import Path
import pandas as pd
from plotnine import (
    ggplot,
    aes,
    geom_histogram,
    geom_bar,
    geom_col,
    facet_wrap,
    labs,
)

data_dir = Path("data")
```

Trong Bài 6–10, ưu tiên diễn đạt đồ họa theo cấu trúc **dữ liệu → ánh xạ (`aes`) → dạng hình học (`geom_*`) → điều kiện hóa/facet**. Đọc file local trong `data/` như đã hướng dẫn ở mục *Chuẩn bị dữ liệu*. Không dùng URL trực tiếp hoặc CSV mirror trong mã nộp.

Bài 6 — Khi số đếm thô biến thành đồ họa gây hiểu sai: `county`

Dùng bộ OpenIntro `county` (3142 quận/hạt của Hoa Kỳ), tối thiểu các biến `poverty` và `metro`.

Dữ liệu và mã khởi động

Sử dụng file `data/county.csv` đã tải ở mục **Chuẩn bị dữ liệu**.

```
import pandas as pd
county = pd.read_csv("data/county.csv")
```

Câu hỏi: phân phối tỉ lệ nghèo của các county thuộc khu vực metro và non-metro khác nhau như thế nào?

1. Trước hết, vẽ hai histogram với **cùng bin edges** nhưng trục y là **số county**.
2. Ghi lại kích thước hai nhóm. Từ đó giải thích vì sao chỉ nhìn chiều cao số đếm có thể đánh đồng "nhóm đông hơn" với "phân phối tập trung hơn".
3. Vẽ lại bằng tỉ lệ hoặc density sao cho diện tích mỗi histogram tương ứng với 100% của **chính nhóm đó**.
4. Viết 4–6 câu so sánh hai phân phối: vị trí, độ trải rộng, đuôi và vùng chồng lấp. Không được chỉ nêu hai số trung bình.
5. Một người chọn bin width khác nhau cho metro và non-metro để "làm hình đẹp hơn". Hãy giải thích vì sao điều này làm so sánh khó kiểm chứng.

Nguồn dữ liệu chính thức: OpenIntro `county`; sử dụng bản local `data/county.csv` đã tải ở mục **Chuẩn bị dữ liệu**.

Bài 7 — Heaping ở chữ số cuối: `run10`

Dùng OpenIntro `run10`, dữ liệu người hoàn thành Cherry Blossom 10-mile run. Xét biến `age`.

Dữ liệu và mã khởi động

Sử dụng file `data/run10.csv` đã tải ở mục **Chuẩn bị dữ liệu**.

```
import pandas as pd
run10 = pd.read_csv("data/run10.csv")
```

1. Bỏ tuổi thiếu. Tạo biến `last_digit = age % 10`.
2. Vẽ biểu đồ tỉ lệ cho 10 chữ số cuối 0–9.

3. Nếu các chữ số cuối phân bố gần đều, mỗi chữ số sẽ ở quanh 10%; đây chỉ là **mốc tham chiếu mô tả**, chưa phải kiểm định giả thuyết. So sánh dữ liệu với mốc này.
4. Tính tổng tỉ lệ tuổi kết thúc bằng `0` hoặc `5`. Có dấu hiệu "heaping" tại các số tròn không?
5. Điều kiện hóa theo `gender` **hoặc** theo `div` và kiểm tra xem hình dạng có còn tương tự không.
6. Nêu ít nhất hai cơ chế khác nhau có thể tạo ra mẫu hình chữ số cuối không đều. Vì sao biểu đồ một mình chưa đủ để kết luận người chạy "khai gian tuổi"?

Nguồn dữ liệu chính thức: OpenIntro `run10`; sử dụng bản local `data/run10.csv` đã tải ở mục **Chuẩn bị dữ liệu**.

Bài 8 — Một đỉnh bất thường có phải là bằng chứng thao túng? `exam_grades`

Dùng OpenIntro `exam_grades` gồm điểm ba bài thi và `course_grade` của 233 sinh viên qua nhiều học kỳ.

Dữ liệu và mã khởi động

Sử dụng file `data/exam_grades.csv` đã tải ở mục **Chuẩn bị dữ liệu**.

```
import pandas as pd
exam_grades = pd.read_csv("data/exam_grades.csv")
```

Một sinh viên nhìn histogram `course_grade` và nói:

> "Nếu có một đỉnh ngay trên một mốc điểm quen thuộc thì chắc giảng viên đã nâng điểm cho sinh viên qua mốc."

Hãy điều tra khẳng định này.

1. Vẽ histogram `course_grade` với bin width 5 điểm.
2. Vẽ lại với bin width 1 điểm. Ghi rõ các bin edges.
3. Xác định các đỉnh, khoảng trống hoặc điểm tụ quanh các mốc tròn nếu có. Mẫu hình nào **ổn định** khi đổi bin width, mẫu hình nào biến mất?
4. Điều kiện hóa theo `semester`: cùng một cấu trúc có lặp lại qua các học kỳ hay chủ yếu đến từ một học kỳ?
5. Kiểm tra xem các điểm `exam1`, `exam2`, `exam3` có hiện tượng tương tự không.
6. Viết một kết luận tối đa 120 từ trả lời: dữ liệu này cung cấp **bằng chứng mô tả** gì, và chưa đủ để chứng minh điều gì về việc "nâng điểm" hay "rigging"?

Nguồn dữ liệu chính thức: OpenIntro `exam_grades`; sử dụng bản local `data/exam_grades.csv` đã tải ở mục **Chuẩn bị dữ liệu**.

Bài 9 — Nhìn gộp hay nhìn trong nhóm? `loans_full_schema`

Dùng OpenIntro `loans_full_schema` (10,000 khoản vay đã được thực hiện).

Dữ liệu và mã khởi động

Sử dụng file `data/loans_full_schema.csv` đã tải ở mục **Chuẩn bị dữ liệu**.

```
import pandas as pd
loans = pd.read_csv("data/loans_full_schema.csv")
```

Tập trung vào:

- `interest_rate`;
- `grade`;
- `homeownership`;
- có thể dùng thêm `loan_amount` hoặc `verified_income` nếu cần giải thích cấu trúc.

Một báo cáo sơ bộ viết:

> "Người thuê nhà (`RENT`) trong dữ liệu này chịu lãi suất cao hơn người có nhà, nên trạng thái sở hữu nhà trực tiếp quyết định lãi suất."

1. Tính và biểu diễn phân phối `interest_rate` theo `homeownership` ở mức **biên**.
2. Sau đó điều kiện hóa theo `grade`: trong từng grade, so sánh `RENT` với `MORTGAGE`/`OWN` bằng cùng một loại tóm tắt.
3. Kết luận biên có giữ nguyên về độ lớn và chiều trong mọi grade không? Nếu không, chỉ ra nơi khác biệt.
4. Giải thích bằng **trọng số nhóm**: phân bố `grade` có giống nhau giữa các nhóm `homeownership` không?
5. Nếu kết luận thay đổi sau điều kiện hóa, có nhất thiết phải gọi đó là "nghịch lý Simpson" không? Nêu tiêu chuẩn tối thiểu để dùng cụm từ "đảo chiều".
6. Quan trọng: dữ liệu chỉ gồm **các khoản vay đã thực sự được cấp/thực hiện**. Vì sao từ đây không thể suy ra đơn giản về mọi người nộp đơn vay, và càng không thể khẳng định quan hệ nhân quả?

Nguồn dữ liệu chính thức: OpenIntro `loans_full_schema`; sử dụng bản local `data/loans_full_schema.csv` đã tải ở mục **Chuẩn bị dữ liệu**.

Bài 10 — Histogram của "các ca xảy ra" không phải histogram của "nguy cơ": `ncbirths`

Dùng OpenIntro `ncbirths`, mẫu ngẫu nhiên 1000 ca sinh tại North Carolina. Tập trung vào `mage` và `premie`.

Dữ liệu và mã khởi động

Sử dụng file `data/ncbirths.csv` đã tải ở mục **Chuẩn bị dữ liệu**.

```
import pandas as pd
ncbirths = pd.read_csv("data/ncbirths.csv")
```

Một người chỉ giữ các ca `premie`, vẽ histogram tuổi mẹ `mage`, thấy một khoảng tuổi có nhiều ca sinh non nhất rồi viết:

> "Nguy cơ sinh non cao nhất ở khoảng tuổi có cột histogram cao nhất."

Hãy kiểm tra logic này.

1. Lọc chỉ các ca `premie` và vẽ histogram `mage` với các nhóm tuổi 5 năm. Đây là **phân phối của cái gì**?
2. Với cùng các nhóm tuổi, đếm **tất cả ca sinh** trong từng nhóm tuổi mẹ.
3. Tính

$$\text{prematurity rate trong nhóm tuổi} = \frac{\text{số ca premie trong nhóm tuổi}}{\text{tổng số ca sinh trong nhóm tuổi}}.$$

4. Vẽ hai đồ họa cạnh nhau về mặt ý tưởng (không cần subplot):
   - số ca `premie` theo nhóm tuổi;
   - tỉ lệ `premie` theo nhóm tuổi.
5. Nhóm có **nhiều ca sinh non nhất** có nhất thiết là nhóm có **tỉ lệ sinh non cao nhất** không? Báo cáo kết quả thật của dữ liệu.
6. Giải thích lỗi mẫu số trong phát biểu ban đầu. Nêu một ví dụ ngoài y tế có cùng lỗi logic.
7. Điều kiện hóa thêm theo `habit` (smoker/nonsmoker) **hoặc** `mature` và mô tả điều gì thay đổi. Không suy diễn nhân quả.

Nguồn dữ liệu chính thức: OpenIntro `ncbirths`; sử dụng bản local `data/ncbirths.csv` đã tải ở mục **Chuẩn bị dữ liệu**.