Problem Set 04 — Tương quan và hồi quy

UET.MAT1052 — Xác suất thống kê

Hoàng Thị Điệp, Nghiêm Nguyễn Việt Dũng, Lê Thị Hường

Mục tiêu

Problem Set 04 luyện các ý cốt lõi của Week 04 về **tương quan và hồi quy**, với trọng tâm không chỉ tính được một hệ số mà còn hiểu **cơ chế tạo ra hệ số đó và giới hạn của kết luận từ mô hình**.

Sau khi hoàn thành problem set, sinh viên có thể:

1. tính **hệ số tương quan Pearson** từ dữ liệu thô và giải thích ý nghĩa của dấu, độ lớn và giới hạn của (r);
2. tự dựng **đường hồi quy bình phương tối thiểu** từ một tập dữ liệu nhỏ, thay vì chỉ gọi hàm có sẵn trong phần mềm;
3. tính và diễn giải **giá trị khớp, phần dư và SSE**, đồng thời kiểm tra các tính chất đại số cơ bản của nghiệm bình phương tối thiểu;
4. hiểu ảnh hưởng của **thay đổi đơn vị, biến chỉ báo và mức tham chiếu** tới hệ số hồi quy;
5. đọc và diễn giải hệ số trong **hồi quy tuyến tính nhiều biến** theo nguyên tắc *giữ các biến còn lại cố định*;
6. nhận ra các trường hợp mà một hệ số tương quan hoặc đường hồi quy đơn lẻ có thể che giấu **cấu trúc nhóm, Simpson's paradox hoặc quan hệ phi tuyến**;
7. phân biệt **mối liên hệ thống kê, khả năng dự đoán và kết luận nhân quả**, tránh suy diễn vượt quá thông tin mà dữ liệu hỗ trợ;
8. thực hiện các phép tính cốt lõi của tương quan và hồi quy **bằng tay trên dữ liệu nhỏ**, qua đó hiểu những gì phần mềm thống kê thực hiện phía sau một lệnh tính toán.

Chuẩn bị dữ liệu

1. Với dữ liệu OpenIntro/IMS, tải tệp CSV từ **trang dữ liệu chính thức**, lưu vào thư mục `data/`, rồi đọc **file local** bằng `pandas`.
2. Không dùng `pd.read_csv("https://...")` cho các tệp OpenIntro/IMS trong bài nộp. Các URL ở phần **Nguồn dữ liệu** chỉ dùng để xác định nguồn và tải dữ liệu.

3. Khi đã có file local, dùng đường dẫn tương đối từ file `.qmd`, ví dụ:

```
import pandas as pd

books = pd.read_csv("data/allbacks.csv")
```

Cấu trúc thư mục khuyến nghị nếu cần dùng dữ liệu đầy đủ:

```
problem-set-04/
   problem_set_04.qmd
   data/
       ...
```

> **Lưu ý.** Các bài 1–6 vẫn là **tính tay**. Việc tải dữ liệu hoặc dùng Python để kiểm tra không thay thế yêu cầu trình bày phép tính bằng tay trong bài nộp.

Phần A — 60% TÍNH TAY

Bài 1 — Tự tính Pearson r trên một mẫu chim cánh cụt

Năm quan sát Adelie dưới đây được lấy từ bộ dữ liệu `penguins` dùng trong STAT20. Hai biến là chiều dài mỏ (`bill_length_mm`) và chiều dài cánh bơi (`flipper_length_mm`).

Chim	x: bill length (mm)	y: flipper length (mm)
1	39.1	181
2	39.5	186
3	40.3	195
4	36.7	193
5	39.3	190

1. Tính $\bar{x}$ và $\bar{y}$.
2. Lập bảng gồm năm cột

$$x_i - \bar{x}, \qquad y_i - \bar{y}, \qquad (x_i - \bar{x})(y_i - \bar{y}), \qquad (x_i - \bar{x})^2, \qquad (y_i - \bar{y})^2.$$

3. Không đi qua s_x, s_y, tính trực tiếp

$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2 \sum_i (y_i - \bar{y})^2}}.$$

4. Nếu r của 5 quan sát này gần 0, một sinh viên kết luận: "chiều dài mỏ không giúp ta biết gì về chiều dài cánh bơi của chim cánh cụt". Nêu **hai lý do khác nhau** vì sao kết luận này quá mạnh.

Bài 2 — Tự dựng đường bình phương tối thiểu từ 4 nhà hàng Zagat

Bốn nhà hàng dưới đây là các quan sát trong dữ liệu `zagat` của STAT20. Chỉ dùng hai biến `food` (thang 0–30) và `price` (USD).

Nhà hàng	x: food	y: price
Daniella Ristorante	22	43
Tello's Ristorante	20	32
Pasticcio	20	34
Belluno	22	39

Ta muốn khớp

$$\widehat{price} = b_0 + b_1\, food.$$

1. Tính $\bar{x}, \bar{y}$, rồi tính

$$b_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}, \qquad b_0 = \bar{y} - b_1 \bar{x}.$$

2. Tính $\hat{y}_i$ và phần dư $e_i = y_i - \hat{y}_i$ cho cả 4 nhà hàng. Kiểm tra bằng tay hai điều kiện

$$\sum e_i = 0, \qquad \sum x_i e_i = 0.$$

3. Tính $SSE = \sum e_i^2$.

4. Zagat đổi thang điểm thức ăn từ 0–30 sang 0–100 bằng

$$x^* = \frac{100}{30} x.$$

   Không khớp lại mô hình, hãy viết ngay đường hồi quy theo x^* và cho biết Pearson r thay đổi thế nào.

Bài 3 — Residual "accounting": một mô hình tốt hơn không cần tốt hơn ở mọi điểm

OpenIntro dùng dữ liệu 15 cuốn sách để giải thích `weight` (gram) từ `volume` (cm^3) và loại bìa. Xét hai mô hình đã được khớp trên **toàn bộ 15 cuốn sách**:

$$M_0: \quad \widehat{weight} = 108 + 0.71\, volume,$$

$$M_1: \quad \widehat{weight} = 197.96 + 0.72\, volume - 184.05 I(pb),$$

trong đó $I(pb) = 1$ nếu bìa mềm và bằng 0 nếu bìa cứng.

Chỉ xét bốn cuốn sau để kiểm tra bằng tay:

ID	volume	weight	cover
4	239	350	hb
8	412	250	pb
11	1492	975	pb
13	1010	950	pb

1. Với **mỗi mô hình**, tính $\hat{y}$, residual $e = y - \hat{y}$ và e^2 cho cả bốn cuốn.
2. Tính SSE_0 và SSE_1 **trên riêng bốn quan sát này**. Mô hình nào thắng trên tập con này?
3. Chỉ ra một cuốn sách mà thêm biến `cover` làm **sai số bình phương của riêng quan sát đó lớn hơn**. Vì sao điều này không mâu thuẫn với phương pháp bình phương tối thiểu khi M_1 được khớp trên toàn bộ dữ liệu?

Bài 4 — Tự giải hồi quy nhiều biến bằng 3 phương trình chuẩn

Quay lại bốn nhà hàng ở Bài 2. Đặt

$$W_i = \begin{cases} 1, & \text{nhà hàng ở phía tây Manhattan (west),} \\ 0, & \text{nhà hàng ở phía đông Manhattan (east).} \end{cases}$$

Dữ liệu là:

Nhà hàng	food x	price y	W
Daniella Ristorante	22	43	1
Tello's Ristorante	20	32	1
Pasticcio	20	34	0
Belluno	22	39	0

Khớp mô hình

$$\hat{y} = b_0 + b_1 x + b_2 W.$$

1. Từ ba điều kiện bình phương tối thiểu
$$\sum e_i = 0, \qquad \sum x_i e_i = 0, \qquad \sum W_i e_i = 0,$$
hãy tự lập hệ ba phương trình theo b_0, b_1, b_2.
2. Giải hệ để tìm b_0, b_1, b_2.
3. Tính bốn residual và SSE. So sánh với SSE của mô hình chỉ có `food` ở Bài 2.
4. Không cần đại số dài: giải thích vì sao, khi cùng dùng một tập dữ liệu huấn luyện, thêm một biến giải thích vào mô hình bình phương tối thiểu **không thể làm SSE tối thiểu tăng lên**.

Bài 5 — Đổi mức tham chiếu mà không khớp lại mô hình

Vẫn dùng mô hình OpenIntro

$$\widehat{weight} = 197.96 + 0.72\, volume - 184.05 I(pb),$$

với bìa cứng (`hb`) là mức tham chiếu.

1. Định nghĩa $H = 1$ nếu `hb`, $H = 0$ nếu `pb`. **Không khớp lại dữ liệu**, hãy biến đổi đại số để viết mô hình tương đương
$$\widehat{weight} = a_0 + a_1\, volume + a_2 H.$$
Tìm a_0, a_1, a_2.
2. Với một cuốn có `volume = 900`, tính dự đoán cân nặng nếu là `hb` và nếu là `pb` bằng **cả hai cách mã hóa**. Hai cặp kết quả phải trùng nhau.
3. Đại lượng nào không đổi khi ta đổi mức tham chiếu: khoảng cách dự đoán giữa hai loại bìa, hệ số chặn, dấu của hệ số dummy, hay cả ba? Giải thích.
4. Hệ số chặn mới có nên được diễn giải như cân nặng thực tế của một cuốn sách "0 cm^3" không?

Bài 6 — Tự chạy mô hình STAT20 `penguins` trên giấy

STAT20 khớp hai mô hình cho `flipper_length_mm`:

$$M_1: \quad \widehat{flipper} = 127.330 + 1.674\, bill_length,$$

và

$$M_2: \quad \widehat{flipper} = 147.563 + 1.096\, bill_length \\ - 5.247 I(Chinstrap) + 17.552 I(Gentoo),$$

với Adelie là mức tham chiếu.

1. Với `bill_length_mm = 43`, tính dự đoán của M_2 cho **Adelie, Chinstrap và Gentoo**.
2. Đổi mức tham chiếu sang Chinstrap. Không dùng phần mềm và không khớp lại dữ liệu, hãy viết toàn bộ phương trình mới của M_2.
3. Dùng phương trình mới để kiểm tra lại dự đoán cho một Gentoo có mỏ dài 43 mm.
4. M_1 có slope 1.674, còn slope của `bill_length_mm` trong M_2 chỉ là 1.096. Hãy viết **một câu diễn giải đúng** cho mỗi slope và nêu vì sao không có mâu thuẫn giữa hai con số.

Phần B — 40% FREEDMAN

Bài 7 — Một tương quan âm được tạo từ ba tương quan dương

Trong toàn bộ dữ liệu Palmer Penguins, tương quan giữa `bill_length_mm` và `bill_depth_mm` xấp xỉ

$$r_{all} = -0.235.$$

Nhưng khi tính riêng theo loài, ta thu được xấp xỉ:

Species	r(bill length, bill depth)
Adelie	+0.391
Chinstrap	+0.654
Gentoo	+0.643

Không cần tính thêm hệ số tương quan.

1. Bốn con số trên có thể đồng thời đúng không? Giải thích bằng hình học của scatterplot và vị trí các cụm loài.
2. Một nhà sinh học hỏi: "Trong **cùng một loài**, cá thể có mỏ dài hơn có xu hướng có mỏ sâu hơn hay nông hơn?" Nên dùng r_{all} hay ba r theo loài? Vì sao?
3. Một nhà phân tích nói: "Vì $r_{all} < 0$, làm mỏ dài thêm sẽ làm mỏ nông đi." Chỉ ra **hai lỗi logic khác nhau** trong câu này.
4. Nếu chỉ được thêm **một biến** vào hồi quy `bill_depth ~ bill_length`, bạn sẽ thêm biến nào trước? Giải thích bằng cấu trúc dữ liệu chứ không bằng p-value.

Bài 8 — Từ bang xuống cá nhân: đâu là ecological fallacy?

Trong ví dụ OpenIntro dùng ở Week 04, mỗi điểm là **một bang của Hoa Kỳ (và DC)**. Gọi

- `Graduates`: tỷ lệ tốt nghiệp trung học của bang;
- `Poverty`: tỷ lệ dân số dưới ngưỡng nghèo.

Tóm tắt cho thấy

$$r \approx -0.747, \qquad \widehat{Poverty} = 64.68 - 0.62\, Graduates.$$

Xét bốn phát biểu:

A. "Các bang có tỷ lệ tốt nghiệp trung học cao hơn có xu hướng có tỷ lệ nghèo thấp hơn."
B. "Một người có bằng trung học sẽ có xác suất nghèo thấp hơn một người không có bằng trung học đúng 0.62 điểm phần trăm."
C. "Nếu một bang nâng `Graduates` thêm 10 điểm phần trăm thì chính sách đó sẽ làm `Poverty` giảm khoảng 6.2 điểm phần trăm."
D. "$r = -0.747$ là bằng chứng khá mạnh về một quan hệ tuyến tính âm ở **cấp bang**, nhưng tự nó chưa xác định cơ chế nhân quả."

1. Với mỗi phát biểu A–D, phân loại thành **được dữ liệu hỗ trợ ở mức mô tả / không được suy ra / phát biểu nhân quả vượt quá dữ liệu**, và giải thích.
2. B và C sai vì **hai lý do khác nhau**. Gọi đúng tên hai vấn đề thống kê đó.
3. Nêu một biến gây nhiễu hợp lý ở cấp bang và mô tả ngắn cách nó có thể tạo ra hoặc làm mạnh thêm quan hệ quan sát được.

Bài 9 — Hai đường hồi quy không phải là hai cách viết của cùng một đường

Với toàn bộ `penguins`, STAT20 cho mô hình dự đoán chiều dài cánh bơi từ chiều dài mỏ

$$\widehat{flipper} = 127.330 + 1.674\, bill_length,$$

và tương quan giữa hai biến xấp xỉ $r = 0.656$.

Một sinh viên muốn dự đoán `bill_length` từ `flipper_length` nên giải ngược phương trình:

$$\widehat{bill_length} = \frac{flipper_length - 127.330}{1.674}.$$

1. Phương trình "giải ngược" này có phải tự động là đường bình phương tối thiểu để dự đoán `bill_length` từ `flipper_length` không?
2. Dùng công thức slope theo đơn vị gốc

$$b_{y|x} = r\frac{s_y}{s_x}, \qquad b_{x|y} = r\frac{s_x}{s_y},$$

   chứng minh rằng slope của đường thứ hai chỉ bằng nghịch đảo slope của đường thứ nhất trong một trường hợp đặc biệt. Nêu trường hợp đó.
3. Giải thích trực giác: tại sao "tối thiểu hóa khoảng cách thẳng đứng theo y" và "tối thiểu hóa khoảng cách thẳng đứng theo x" là hai bài toán khác nhau khi đám mây điểm không nằm hoàn toàn trên một đường thẳng?
4. Với $r = 0.656$, bạn kỳ vọng sai khác giữa hai đường là đáng kể hay gần như bằng 0? Giải thích mà không cần khớp đường thứ hai.

Bài 10 — "Đường hồi quy có ý nghĩa không?": bốn kết luận, bốn loại bẫy

Bốn nhà phân tích cùng dùng các bộ dữ liệu của STAT20/OpenIntro sau Week 04.

I. Zagat. Từ 168 nhà hàng Ý ở Manhattan, mô hình

$$\widehat{price} = -24.5 + 1.64\, food + 1.88\, decor$$

được dùng để dự đoán giá cho một nhà hàng có `food = 40`, `decor = 35`.

II. Books. Từ dữ liệu sách,

$$\widehat{weight} = 197.96 + 0.72\, volume - 184.05 I(pb).$$

Một báo cáo diễn giải 197.96 là "cân nặng điển hình của cuốn sách bìa cứng có thể tích 0 cm^3".

III. Penguins. Vì hồi quy gộp `bill_depth ~ bill_length` có slope âm, một báo cáo bỏ qua `species` và mô tả đó là "xu hướng hình thái chung cho mọi loài".

IV. Poverty–Graduates. Vì slope ở cấp bang là âm, một báo cáo kết luận tăng tốt nghiệp trung học **sẽ** làm giảm nghèo với đúng tốc độ của slope quan sát.

Với mỗi trường hợp I–IV:

1. Gọi tên **bẫy thống kê chính** trong một cụm từ ngắn.
2. Viết lại kết luận thành một câu **thận trọng nhưng vẫn hữu ích** mà dữ liệu/mô hình thực sự cho phép nói.
3. Chọn **một** trong bốn trường hợp và nêu dữ liệu hoặc thiết kế nghiên cứu bổ sung nào sẽ giúp biến kết luận hiện tại thành một kết luận mạnh hơn.